

La Computación Paralela en el Aula y en la Profesión

Plan de entrevista

Luis Francisco Padilla

Estuardo Castro

26 de septiembre de 2026

Índice

1. Objetivo de la entrevista	1
2. Perfil del entrevistado	1
3. Estructura del episodio	2
4. Preguntas planificadas	2
4.1. Bloque 1: Introducción del entrevistado y su profesión	2
4.2. Bloque 2: Aplicaciones de la computación paralela en su campo	3
4.3. Bloque 3: Herramientas y tecnologías paralelas	4
4.4. Bloque 4: Desafíos y beneficios	4
4.5. Bloque 5: Tendencias futuras	4
4.6. Cierre	5
5. Preguntas de reserva	5
6. Cobertura de los temas requeridos	5
7. Resumen de los puntos clave que esperamos cubrir	5
8. Logística de grabación	5

1. Objetivo de la entrevista

Mostrar cómo los conceptos del curso Computación Paralela y Distribuida se usan en la práctica profesional de un exalumno de la Universidad del Valle de Guatemala que trabaja en *machine learning*. Queremos que el oyente vea la relación entre la teoría (hilos, sincronización, condiciones de carrera, ley de Amdahl, memoria compartida y paso de mensajes) y las decisiones que un ingeniero toma en proyectos reales con restricciones de tiempo, costo y negocio.

2. Perfil del entrevistado

Campo	Detalle
Nombre	Daniel Valdez
Formación	Ingeniería en Ciencias de la Computación y Tecnologías de la Información, UVG
Puesto actual	Machine Learning Engineer en Improgress (Guatemala)
Área de trabajo	Automatización, productos para clientes y puesta en producción de modelos de IA
Por qué lo elegimos	Aplica paralelismo y computación distribuida para servir modelos, cumplir requisitos de latencia y escalar sistemas

3. Estructura del episodio

La duración objetivo es de 30 a 45 minutos.

Bloque	Duración estimada	Responsable	Contenido
1. Introducción	2 min	Estuardo	Bienvenida, tema del episodio y presentación de los anfitriones
2. Presentación del invitado	5 min	Luis y el invitado	Trayectoria y rol actual
3. Aplicaciones del paralelismo	12 min	Ambos	Ejemplos concretos en su trabajo
4. Herramientas y tecnologías	8 min	Estuardo	Librerías, frameworks y técnicas
5. Desafíos y beneficios	8 min	Luis	Límites, costos y decisiones de diseño
6. Tendencias futuras	6 min	Estuardo	Hacia dónde va el paralelismo
7. Cierre	2 min	Luis y Estuardo	Agradecimientos y mensaje final

4. Preguntas planificadas

Cada bloque tiene preguntas principales, puntos clave que esperamos cubrir y preguntas de seguimiento por si la respuesta necesita más detalle.

4.1. Bloque 1: Introducción del entrevistado y su profesión

P1. ¿Quién eres y a qué te dedicas actualmente?

Puntos clave esperados:

- Formación en la UVG y año de graduación.
- Empresa y puesto actual.

- Tipo de proyectos en los que participa.

P2. ¿Qué hace un Machine Learning Engineer y en qué se diferencia de un *data scientist* o de un desarrollador *backend*?

Puntos clave esperados:

- El ciclo de vida de un modelo: diseño, puesta en producción, consumo y mantenimiento.
- El ML Engineer como puente entre quien diseña el modelo y quien lo consume.
- Las ventajas de tener un rol especializado en lugar de tratar el modelo como un *endpoint* más.

Seguimiento:

- ¿Qué problemas aparecen cuando un equipo no tiene esta figura y el modelo llega “en crudo” al *backend*?
- ¿Qué métricas vigilas? ¿En qué se diferencian las métricas de un sistema de las de un modelo?

4.2. Bloque 2: Aplicaciones de la computación paralela en su campo

P3. ¿En qué momentos de tu trabajo el paralelismo o la computación distribuida te facilitan la vida?

Puntos clave esperados:

- Requisitos de latencia: modelos que responden en milisegundos frente a procesos que tardan minutos.
- Tareas largas que no deben bloquear el hilo principal de una API.
- Colas de tareas y *workers* en segundo plano.
- *Pipelines* de limpieza y procesamiento de datos.

Seguimiento:

- ¿Cómo evitas que una tarea pesada congele un servicio como FastAPI?
- ¿Tienes un ejemplo concreto de un proyecto donde paralelizar haya cambiado el resultado?

P4. ¿Qué técnicas usas para que los procesos corran lo más rápido posible y con el menor *delay*?

Puntos clave esperados:

- Por qué no basta con agregar más hilos.
- El *overhead* y el consumo de recursos por hilo.
- La relación con la **ley de Amdahl**: la parte secuencial limita la aceleración.

Seguimiento:

- ¿Cómo detectas que llegaste al punto en que agregar hilos ya no ayuda?

P5. En demos y pruebas de concepto, ¿la optimización es opcional? ¿Alguna vez la paralelización fue lo que le dio valor al producto?

Puntos clave esperados:

- Qué prioriza una demo frente a un sistema en producción.
- Ejemplos de sistemas donde la latencia es crítica, como el *streaming*.
- Casos en que optimizar desde el inicio ahorra tiempo de desarrollo.
- Diseño de arquitectura y topología para producción.

4.3. Bloque 3: Herramientas y tecnologías paralelas

P6. Además de PyTorch, ¿qué librerías o tecnologías usas para paralelizar el manejo de datos?

Puntos clave esperados:

- Hilos de Python, subprocesos y Pthreads en C.
- Colas de trabajo y *thread pools* con asignación dinámica.
- Semáforos y otros mecanismos de sincronización.
- SDKs específicos del dominio, como los de cámaras.

Seguimiento:

- ¿Tienes un proyecto actual que ilustre estas herramientas? ¿Cómo lo vas a escalar?
- ¿Cómo evitas las condiciones de carrera cuando varios hilos procesan fuentes de datos distintas?
- ¿Usas herramientas como OpenMP, CUDA o MPI, o frameworks distribuidos en la nube?

4.4. Bloque 4: Desafíos y beneficios

P7. ¿Cuáles son los principales desafíos de llevar el paralelismo a un sistema real?

Puntos clave esperados:

- Condiciones de carrera, memoria compartida y paso de mensajes.
- El costo económico de una mala decisión, como el tiempo de servidor facturado en AWS.
- El balance entre latencia, costo, complejidad y funcionalidad.

P8. ¿Cómo justificas una decisión de arquitectura paralela ante personas no técnicas?

Puntos clave esperados:

- Decisiones respaldadas con datos, no con la opinión de una herramienta de IA.
- Explicar los *trade-offs* en términos de negocio: si quieres X, sacrificas B.
- Las reglas del negocio como guía del diseño.
- Criterios claros para saber cuándo el trabajo está terminado.

Seguimiento:

- ¿Tienes un ejemplo de cliente en que tuviste que explicar este tipo de *trade-off*?

4.5. Bloque 5: Tendencias futuras

P9. ¿Cómo ves el futuro del paralelismo y del *machine learning*? ¿Qué nos espera a quienes estamos por graduarnos?

Puntos clave esperados:

- La vigencia del paralelismo como técnica de optimización.
- Planificación y asignación dinámica de tareas asistida por IA.
- La computación cuántica y su impacto en la forma de diseñar sistemas.
- Qué habilidades conviene desarrollar desde ahora.

Seguimiento:

- ¿Crees que una IA podría encargarse de balancear cargas y reducir condiciones de carrera?

- Si la computación cuántica llega al mercado, ¿qué cambiaría en nuestro trabajo como ingenieros?

4.6. Cierre

P10. ¿Algún mensaje final para quienes nos escuchan?

5. Preguntas de reserva

Estas preguntas se usan si sobra tiempo o si algún bloque se agota antes de lo previsto:

1. ¿Qué tema del curso de Computación Paralela y Distribuida te ha servido más en tu trabajo?
2. ¿Usas GPU en tus proyectos? ¿Cuándo conviene entrenar o hacer inferencia en GPU frente a CPU?
3. ¿Qué diferencia práctica ves entre usar hilos y procesos en Python, considerando el GIL?
4. ¿Qué consejo le darías a un estudiante que quiere especializarse en MLOps o *machine learning engineering*?
5. ¿Qué recurso (libro, curso o documentación) recomendarías para profundizar en paralelismo?

6. Cobertura de los temas requeridos

Tema requerido por la rúbrica	Preguntas que lo cubren
Introducción del entrevistado y su profesión	P1, P2
Ejemplos de aplicación de la computación paralela	P3, P4, P5
Herramientas y tecnologías paralelas	P6
Desafíos y beneficios	P4, P5, P7, P8
Tendencias futuras	P9

7. Resumen de los puntos clave que esperamos cubrir

- **Rol profesional:** el ML Engineer como puente entre el diseño del modelo y su consumo en producción.
- **Métricas:** la diferencia entre métricas del sistema (latencia, carga, tráfico) y métricas del modelo (calidad de las predicciones y KPIs de negocio).
- **Aplicación práctica:** colas de tareas, *workers* y ejecución en segundo plano para no bloquear servicios.
- **Límites teóricos:** la ley de Amdahl y el *overhead* de crear hilos sin necesidad.
- **Sincronización:** semáforos para prevenir condiciones de carrera.
- **Caso real:** escalar un sistema de visión por computadora de 5 a 50 cámaras sin perder latencia.
- **Negocio:** decisiones técnicas fundamentadas y alineadas con las reglas del negocio.
- **Futuro:** asignación dinámica de tareas con IA y el impacto de la computación cuántica.

8. Logística de grabación

Aspecto	Plan
Modalidad	Videollamada con grabación local de video y transcripción automática
Grabación	OBS en la computadora de Estuardo
Prueba de audio	Revisar eco y niveles con el invitado antes de empezar
Edición	Recortar la charla previa a la introducción de Estuardo y todo lo que sigue a la frase final del invitado, eliminar pausas y ruido, normalizar niveles y agregar música de entrada y salida
Respaldo	Guardar la transcripción de la llamada para las notas del show